

# Formális nyelvek és a fordítóprogramok alapjai

## 2. előadás

Előadó: Nagy Sára, mesteroktató  
Algoritmusok és Alkalmazásai Tanszék

## Emlékeztető:

$V$  - ábécé, jelek nem üres véges halmaza;

$V^*$  - az adott jelkészlet felett értelmezett összes szó;

$L \subseteq V^*$  - formális nyelv, szavak halmaza.

# Nyelv megadása szabályrendszerrel

Definíció: Grammatikának (nyelvtannak) a következő négyest nevezzük:

$G=(N,T,P,S)$

- $N$  a nemterminális ábácé,
- $T$  a terminálisok ábécéje,
- $P$  az átírási szabályok véges halmaza,
- $S$  a kezdőszimbólum.

# Grammatika: $G=(N,T,P,S)$

- ▶  $N$  és  $T$  diszjunkt halmazok, azaz  $N \cap T = \emptyset$ .
- ▶  $S \in N$ , kezdőszimbólum.
- ▶ A szabályok  $p \rightarrow q$  alakúak, ahol  $p \in (N \cup T)^* N (N \cup T)^*$ ,  $q \in (N \cup T)^*$  és  $p$  jelöli a szabály baloldalát,  $q$  a jobboldalát,  $\rightarrow$  a két oldalt elválasztó jel.
- ▶ A szabályok baloldala kötelezően tartalmaz legalább egy nemterminális szimbólumot.
- ▶  $(N \cup T)^*$  elemeit *mondatformáknak* nevezzük.

# Grammatika által generált nyelv

Minden olyan szó, amely közvetetten levezethető a kezdőszimbólumból.

$$L(G) := \{ u \in T^* \mid S \xRightarrow[G]{*} u \}$$

# Generatív grammatika (nyelvten)

Példa:

$G = (\{S\}, \{a,b\}, \{S \rightarrow aSb, S \rightarrow ab\}, S)$  egy grammatika.

Ez a grammatika az  $L = \{ a^n b^n \mid n \geq 1 \}$  nyelvet definiálja.

Levezetés:

$$S \xRightarrow{G} aSb \xRightarrow{G} aaSbb \xRightarrow{G} aaaSbbb \xRightarrow{G} aaaabbbb$$
$$S \xRightarrow{G}^* a^4b^4$$

# Közvetlen levezetés

Legyen  $G = (N, T, P, S)$  egy adott grammatika.

Legyen  $u, v \in (N \cup T)^*$ .

Azt mondjuk, hogy a  $v$  mondatforma **közvetlenül** levezethető az  $u$  mondatformából, ha létezik  $u_1, u_2 \in (N \cup T)^*$  és  $x \rightarrow y \in P$  úgy, hogy  $u = u_1xu_2$  és  $v = u_1yu_2$ .

Jelölése:  $u \Rightarrow_G v$

# Példa

$u = ab\textcolor{red}{Bca}aAcb$

$v = ab\textcolor{red}{caBA}aAcb$

$Bca \rightarrow caBA \in P$

Az  $u$  modatformából közvetlenül levezethető a  $v$  mondatforma a megadott szabály segítségével.

$\underline{ab}\textcolor{red}{Bca}\underline{aAcb} \xRightarrow{G} \underline{ab}\textcolor{red}{caBA}\underline{aAcb}$ , ahol  $u_1=ab$  és  $u_2=aAcb$



## Közvetett levezetés

Legyen  $G = (N, T, P, S)$  egy adott grammatika.

Legyen  $u, v \in (N \cup T)^*$ .

Azt mondjuk, hogy a  $v$  mondatforma **közvetetten** levezethető az  $u$  mondatformából, ha létezik olyan  $k \geq 0$  szám és  $x_0, \dots, x_k \in (N \cup T)^*$ , hogy  $u = x_0$  és  $v = x_k$  és  $\forall i \in [0, k-1]: x_i \xRightarrow{G} x_{i+1}$ .

Jelölése:  $u \xRightarrow{*}_G v$

# Grammatika által generált nyelv

Minden olyan szó, amely közvetetten levezethető a kezdőszimbólumból.

$$L(G) := \{ u \in T^* \mid S \xRightarrow[G]{*} u \}$$

# Példa:

$G = (\{S,A,B\}, \{a,b\}, P, S)$  egy grammatika.

$P: S \rightarrow ASB$

$S \rightarrow AB$

$AB \rightarrow BA$  //csere szabály

$A \rightarrow a$

$B \rightarrow b$

$L(G) = \{ u \in \{a,b\}^* \mid \ell_a(u) = \ell_b(u) \geq 1 \}$  nyelvet definiálja.

(Ugyanannyi ,a' és ,b' betű van a szavakban.)

Levezetés (példa egy szó levezetésére):

$$S \xRightarrow[G]{*} A^n B^n \xRightarrow[G]{} A^{n-1} B A B^{n-1} \xRightarrow[G]{*} B A^{n-1} A B^{n-1} \xRightarrow[G]{*} b a^n b^{n-1}$$


# Ekvivalencia

A  $G_1$  es  $G_2$  nyelvtanok **ekvivalensek**, ha

$L(G_1) = L(G_2)$ , azaz ugyanazt a nyelvet generálják.

Gyengén ekvivalensek, ha  $L(G_1) \setminus \{\varepsilon\} = L(G_2) \setminus \{\varepsilon\}$ .

# Noam Chomsky (született: 1928)



Noam Chomsky amerikai nyelvész, a Massachusetts Institute of Technology professzora, a generatív nyelvtan elméletének megalkotója, filozófus, politikai aktivista, előadó és lektor. Kidolgozója a róla elnevezett Chomsky-hierarchiának. (Wikipédia)

# Chomsky féle grammatika típusok

**Definíció:** A  $G = (N, T, P, S)$  grammatika  $i$ -típusú ( $i = 0, 1, 2, 3$ ), ha  $P$  szabályhalmazára teljesülnek a következők:

- $i = 0$ : Nincs korlátozás.
- $i = 1$ :  $P$  minden szabálya  $u_1 A u_2 \rightarrow u_1 v u_2$  alakú, ahol  $u_1, u_2, v \in (N \cup T)^*$ ,  $A \in N$ , és  $v \neq \varepsilon$ , kivéve az  $S \rightarrow \varepsilon$  alakú szabályt, de ekkor  $S$  nem fordul elő egyetlen szabály jobboldalán sem.  
(Ezt "Korlátozott  $\varepsilon$  szabály"-nak, röviden: KES szabálynak hívjuk.)
- $i = 2$ :  $P$  minden szabálya  $A \rightarrow v$  alakú, ahol  $A \in N$ ,  $v \in (N \cup T)^*$ .
- $i = 3$ :  $P$  minden szabálya vagy  $A \rightarrow u B$  vagy  $A \rightarrow u$  alakú, ahol  $A, B \in N$  és  $u \in T^*$ .

# Chomsky féle grammatika típusok

Jelölje  $\mathcal{G}_i$  az  $i$ -típusú grammatikák halmazát.

A grammatikák alakjából következik, hogy

$$\mathcal{G}_i \subseteq \mathcal{G}_0, \text{ ahol } i=1,2,3.$$

$$\mathcal{G}_3 \subseteq \mathcal{G}_2$$

# Nyelvek típusai

Egy  $L$  nyelvet  $i$ -típusúnak nevezünk ( $i \in \{0,1,2,3\}$ ), ha létezik olyan  $i$ -típusú grammatika, ami az  $L$  nyelvet generálja.

Jelölje  $\mathcal{L}_i$  az  $i$ -típusú nyelvek halmazát.  
(Nyelvcsalád.)




# Chomsky féle hierarchia

$$\mathcal{L}_3 \subseteq \mathcal{L}_2 \subseteq \mathcal{L}_1 \subseteq \mathcal{L}_0$$

Pontosabban valódi tartalmazás van

$$\mathcal{L}_3 \subset \mathcal{L}_2 \subset \mathcal{L}_1 \subset \mathcal{L}_0$$



# Chomsky féle grammatika típusok

Típus	Alaptípus szabályai	Speciális alakok szabályai	Normál forma szabályai
0.	Nincs korlátozás.	$p \rightarrow q$ , ahol $p \in N^+$ , $q \in (N \cup T)^*$	
1.	$u_1 A u_2 \rightarrow u_1 v u_2$ , ahol $u_1, u_2, v \in (N \cup T)^*$ , $A \in N$ , és $v \neq \varepsilon$ , kivéve az $S \rightarrow \varepsilon$ , de ekkor $S$ nem fordul elő egyetlen szabály jobboldalán sem. (környezetfüggő grammatika)	$p \rightarrow q$ , ahol $l(p) \leq l(q)$ kivéve az $S \rightarrow \varepsilon$ , de ekkor $S$ nem fordul elő egyetlen szabály jobboldalán sem. (hosszúság nemcsökkentő grammatika)	Kuroda normál forma $A \rightarrow a$ vagy $A \rightarrow B$ vagy $A \rightarrow BC$ vagy $AB \rightarrow CD$ alakúak a szabályok, ahol $a \in T$ és $A, B, C, D \in N$ , kivéve az $S \rightarrow \varepsilon$ , de ekkor $S$ nem fordul elő egyetlen szabály jobboldalán sem.
2.	$A \rightarrow v$ , ahol $v \in (N \cup T)^*$ , $A \in N$ (környezetfüggetlen grammatika)	$A \rightarrow v$ , ahol $v \in (N \cup T)^*$ , $A \in N$ és $v \neq \varepsilon$ , kivéve az $S \rightarrow \varepsilon$ , de ekkor $S$ nem fordul elő egyetlen szabály jobboldalán sem.	Chomsky normál forma $A \rightarrow a$ vagy $A \rightarrow BC$ alakúak a szabályok, ahol $a \in T$ és $A, B, C \in N$ , kivéve az $S \rightarrow \varepsilon$ , de ekkor $S$ nem fordul elő egyetlen szabály jobboldalán sem.
3.	$A \rightarrow uB$ vagy $A \rightarrow u$ , ahol $u \in T^*$ , $A, B \in N$ (reguláris grammatika)	$A \rightarrow aB$ vagy $A \rightarrow a$ , ahol $a \in T$ , és $A, B \in N$ , kivéve az $S \rightarrow \varepsilon$ , de ekkor $S$ nem fordul elő egyetlen szabály jobboldalán sem.	3-as normál forma $A \rightarrow aB$ vagy $A \rightarrow \varepsilon$ , ahol $a \in T$ , és $A, B \in N$ .

# Példa

$$L = \{ u \in \{a,b\}^* \mid \ell_a(u) = \ell_b(u) \geq 0 \}$$

$G_1 = (\{S', S, A, B\}, \{a, b\}, P, S')$  egy grammatika.

$P_1: S' \rightarrow \varepsilon$	KES
$S' \rightarrow S$	0,1,2,3-as típusú szabály
$S \rightarrow ASB$	0,1,2-es típusú szabály
$S \rightarrow AB$	0,1,2-es típusú szabály
$AB \rightarrow BA$	0-s típusú szabály
$A \rightarrow a$	0,1,2,3-as típusú szabály
$B \rightarrow b$	0,1,2,3-as típusú szabály

A  $G_1$  grammatika 0-s típusú.  $G_1 \in \mathcal{G}_0$

# Példa

$$L = \{ u \in \{a,b\}^* \mid \ell_a(u) = \ell_b(u) \geq 0 \}$$

$G_2 = (\{S,A,B\}, \{a,b\}, P, S)$  egy grammatika.

$$P_2: S \rightarrow aSbS$$

$$S \rightarrow bSaS$$

$$S \rightarrow \varepsilon$$

Állítás:  $L = L(G_2)$ .

Bizonyítás: Mivel ,a' és ,b' együtt generálódik, ezért  $L(G_2) \subseteq L$ .

Kérdés, hogy minden L beli szó generálható-e, azaz  $L \subseteq L(G_2)$  ?

# Példa folytatása

Kérdés, hogy minden  $L$  beli szó generálható-e, azaz  $L \subseteq L(G_2)$  ?

Minden szó hossza páros, azaz  $\ell(u) \geq 2 \cdot k$ , ahol  $k \in \mathbb{N}$ .

A tartalmazás  $k$  szerinti teljes indukcióval bizonyítható.

$k=1$  esetén látható, hogy  $S \xRightarrow{G} aSbS \xRightarrow{G}^* ab$  és  $S \xRightarrow{G} bSaS \xRightarrow{G}^* ba$

Tegyük fel, hogy a  $2k$  hosszú szavakat le tudjuk vezetni. Legyen  $\ell(u) = 2 \cdot (k+1)$ .

Ha az  $u$  szó  $a'$ -val kezdődik, akkor biztosan van egy  $b'$  párja, azaz  $u = vw$ , ahol  $v$  az első olyan prefix, hogy  $v \in L$ , azaz  $\ell_a(v) = \ell_b(v)$  és  $v = a'xb'$ .

Ekkor  $x, w \in L$  és  $2 \cdot k \geq \ell(x) \geq 0$  és  $2 \cdot k \geq \ell(w) \geq 0$ .

Így  $S \xRightarrow{G} aSbS \xRightarrow{G}^* a'xbS \xRightarrow{G}^* a'xbw$ , ahol teljes indukciót alkalmazhatunk  $x$  és  $w$  levezetésére.

Ha  $b'$ -vel kezdődne a szó, akkor hasonlóan járunk el.

# Példa

$$L = \{ u \in \{a,b\}^* \mid \ell_a(u) = \ell_b(u) \geq 0 \}$$

$G_2 = (\{S,A,B\}, \{a,b\}, P, S)$  egy grammatika.

$P_2$ :  $S \rightarrow aSbS$       0,1,2-es típusú szabály

$S \rightarrow bSaS$       0,1,2-es típusú szabály

$S \rightarrow \varepsilon$       0,2,3-as típusú szabály (nem KES)

A  $G_2$  grammatika 2-es típusú.  $G_2 \in \mathcal{G}_2$

$L(G_1) = L(G_2)$  , azaz a két grammatika ekvivalens.

Az  $L$  nyelv 2-es típusú, mert van hozzá 2-es típusú grammatika.

$$L \in \mathcal{L}_2$$

---

Lehet, hogy  $L \in \mathcal{L}_3$  ?

Válasz: nem. Bizonyítás később.

# Chomsky féle grammatika típusok

**Definíció:** A  $G = (N, T, P, S)$  grammatika  $i$ -típusú ( $i = 0, 1, 2, 3$ ), ha  $P$  szabályhalmazára teljesülnek a következők:

- $i = 0$ : Nincs korlátozás.
- $i = 1$ :  $P$  minden szabálya  $u_1 A u_2 \rightarrow u_1 v u_2$  alakú,  
ahol  $u_1, u_2, v \in (N \cup T)^*$ ,  $A \in N$ , és  $v \neq \varepsilon$ ,  
kivéve az  $S \rightarrow \varepsilon$  alakú szabályt, de ekkor  $S$  nem fordul elő egyetlen szabály jobb oldalán sem (röviden: KES)
- $i = 2$ :  $P$  minden szabálya  $A \rightarrow v$  alakú, ahol  $A \in N$ ,  $v \in (N \cup T)^*$ .
- $i = 3$ :  $P$  minden szabálya vagy  $A \rightarrow uB$  vagy  $A \rightarrow u$  alakú,  
ahol  $A, B \in N$  és  $u \in T^*$ .

# Chomsky féle hierarchia

$$\mathcal{L}_3 \subseteq \mathcal{L}_2 \subseteq \mathcal{L}_1 \subseteq \mathcal{L}_0$$

Azonban

$$\mathcal{G}_3 \subseteq \mathcal{G}_2 \not\subseteq \mathcal{G}_1 \subseteq \mathcal{G}_0$$

Ha a 2-es típusú szabályoknál is kikötnénk, hogy  $v \neq \varepsilon$ , akkor igaz lenne a tartalmazás, és akkor triviálisan igaz lenne a nyelvcsaládokra is tartalmazás.



# Nyelvtani transzformáció

A nyelvtani transzformáció olyan eljárás, amely egy  $G$  grammatikából egy másik  $G'$  grammatikát készít.

**Ekvivalens** transzformációról beszélünk, ha minden  $G$  grammatikára és az ő  $G'$  transzformáltjára igaz, hogy  $L(G)=L(G')$ .

# $\varepsilon$ -mentesítés

## Tétel:

Minden  $G=(N,T,P,S)$  környezetfüggetlen (2-es típusú) grammatikához megkonstruálható egy vele ekvivalens  $G'=(N',T,P',S')$  környezetfüggetlen grammatika úgy, hogy  $P'$ -ben **nincs**  $A\rightarrow\varepsilon$  alakú szabály, kivéve, ha  $\varepsilon\in L(G)$ , mert akkor  $S'\rightarrow\varepsilon\in P'$ , de ekkor  $S'$  nem szerepelhet szabály jobboldalán.

# $\epsilon$ -mentesítés

Első lépésben meghatározzuk, hogy mely nemterminálisokból vezethető le az üres szó.

$$H := \{ A \in N \mid A \xRightarrow[G]{*} \epsilon \}$$

Ehhez definiáljuk a  $H_i$  ( $i \geq 1$ ) halmazokat:

$$H_1 := \{ A \in N \mid \exists A \rightarrow \epsilon \in P \}$$

$$H_{i+1} := H_i \cup \{ A \in N \mid \exists A \rightarrow w \in P \text{ és } w \in H_i^* \}$$

$$H_1 \subseteq H_2 \subseteq \dots \subseteq H_k = H_{k+1} \exists k \text{ és legyen } H := H_k.$$

## $\varepsilon$ -mentesítés

Ekkor látható,  
ha  $A \in N$  és  $A \xRightarrow[G]{*} \varepsilon$ , akkor, és csak akkor, ha  $A \in H$ .

Ennek következménye, hogy  
 $\varepsilon \in L(G)$ , akkor, és csak akkor, ha  $S \in H$ .

## $\epsilon$ -mentesítés

Második lépésben átalakítjuk  $H$  ismeretében a grammatika szabályait a kellő alakúra.

$S \notin H$  esetén:

$A \rightarrow v' \in P'$  , akkor, és csak akkor, ha  $v' \neq \epsilon$  és  $\exists A \rightarrow v \in P$  úgy, hogy  $v'$ -t  $v$ -ből úgy kapjuk, hogy elhagyunk nulla vagy több  $H$ -beli nemterminálist  $v$ -ből.

# $\epsilon$ -mentesítés

$S \in H$  esetén:

A korábbi szabályokhoz hozzá vesszük még a következő két szabályt:

$$S' \rightarrow \epsilon \text{ és } S' \rightarrow S$$

,ahol  $S' \notin N$  a  $G'$  grammatika új kezdőszimbóluma.

Megjegyzés: Az átalakítás megőrzi a 2. és 3. típust.

## Példa

$$L = \{ u \in \{a,b\}^* \mid \ell_a(u) = \ell_b(u) \geq 0 \}$$

$$G = (\{S\}, \{a,b\}, P, S)$$

$$P: S \rightarrow aSbS$$

$$S \rightarrow bSaS$$

$$S \rightarrow \varepsilon$$

és  $L(G) = L$ . (Ezt korábban bizonyítottuk.)

# Példa

$L = \{ u \in \{a,b\}^* \mid \ell_a(u) = \ell_b(u) \}$  , azaz ugyanannyi „a” és „b” van a szavakban.

$G = (\{S\}, \{a,b\}, P, S)$

$G' = (\{S', S\}, \{a,b\}, P', S')$

$P: S \rightarrow aSbS$

$P': S \rightarrow aSbS$

$S \rightarrow abS$

$S \rightarrow aSb$

$S \rightarrow ab$

$S \rightarrow bSaS$

$S \rightarrow bSaS$

$S \rightarrow baS$

$S \rightarrow bSa$

$S \rightarrow ba$

$S \rightarrow \varepsilon$

$S' \rightarrow \varepsilon, S' \rightarrow S$

és  $L(G) = L(G')$ .



# Példa

u=abba szó levezetése:

$$S \xRightarrow{G} aSbS \xRightarrow{G} aSbbSaS \xRightarrow{G} abbSaS \xRightarrow{G} abbaS \xRightarrow{G} abba$$

$$S' \xRightarrow{G'} S \xRightarrow{G'} abS \xRightarrow{G'} abba$$

# Példa

$G = (\{S, A, B\}, \{a, b\}, P, S)$

$P: S \rightarrow aAS$

$S \rightarrow AaB$

$S \rightarrow AB$

$A \rightarrow BB$

$B \rightarrow bA$

$B \rightarrow \epsilon$

$H_1 = \{B\}$

$H_2 = H_1 \cup \{A\} = \{A, B\}$

$H_3 = H_2 \cup \{S\} = \{A, B, S\} = N$

$H = H_3$

$G' = (\{S', S, A, B\}, \{a, b\}, P', S')$

$P': S \rightarrow aAS \mid aS \mid aA \mid a$

$S \rightarrow AaB \mid aB \mid Aa \mid a$

$S \rightarrow AB \mid B \mid A$

$A \rightarrow BB \mid B$

$B \rightarrow bA \mid b$

$S' \rightarrow \epsilon$

$S' \rightarrow S$

*Köszönöm a figyelmet!*