

# Formális nyelvek és a fordítóprogramok alapjai

6. előadás

Előadó: Nagy Sára, mesteroktató  
Algoritmusok és Alkalmazásaik Tanszék

# Emlékeztető

Chomsky féle hierarchia:

$$\mathcal{L}_3 \subset \mathcal{L}_2 \subset \mathcal{L}_1 \subset \mathcal{L}_0$$

$G=(N,T,P,S)$  grammatika 2-es típusú, ha szabályai

$A \rightarrow u$  alakúak, ahol  $A \in N$ ,  $u \in (N \cup T)^*$

Ezeket nevezzük *környezetfüggetlen* grammatikáknak. Ilyenekkel írható le a programozási nyelvek szintaxisa.

# 2-típusú grammatikák normál formája

## Definíció:

Egy  $G=(N,T,P,S)$  környezetfüggetlen grammatikát **Chomsky normálformájúnak** mondunk, ha szabályai

- $A \rightarrow a$ , ahol  $A \in N$  és  $a \in T$  vagy
- $A \rightarrow BC$  alakúak, ahol  $A,B,C \in N$ .
- $S \rightarrow \varepsilon$ , de ekkor  $S$  nem fordul elő egyetlen szabály jobboldalán sem.

# Chomsky normál forma

## Tétel:

Minden környezetfüggetlen grammatikához megkonstruálható egy vele ekvivalens **Chomsky normálformájú** grammatika.

## Megjegyzés:

- A 2-es típusú grammatikák Chomsky normálformára hozásának algoritmusát nem a tananyag része.
- Chomsky normálformájú grammatikákhoz megadható olyan elemző program, amely  $O(n^3)$  időben eldönti a szóproblémát (Cocke-Younger-Kasami algoritmus).
- Bizonyos állítások bizonyítását elég elvégezni a normálformájú grammatikákra.

# Bar-Hillel lemma (pumpáló lemma)

Minden  $L$  környezetfüggetlen nyelvhez megadható két nyelvtől függő természetes szám  $p$  és  $q$  úgy, hogy

$\forall u \in L$  szóra, ha  $\ell(u) > p$ , akkor  $u$  felírható

$$u = vxwyz$$

alakban, ahol  $v, x, w, y, z \in T^*$  és

- $\ell(xwy) \leq q$ ,
- $xy \neq \varepsilon$ ,
- $vx^iwy^iz \in L, \forall i \geq 0$  esetén.

Megjegyzés: A lemmát nem bizonyítjuk, de a bizonyításhoz szükséges, hogy a 2-es típusú nyelvekhez létezik Chomsky-normálformájú grammatika.

# Következmény

Van olyan nyelv, amely nem környezetfüggetlen.

Például  $L = \{ a^n b^n c^n \mid n > 0 \} \notin \mathcal{L}_2$ .

Tegyük fel indirekt, hogy  $\exists p, q$  a Bar-Hillel lemmának megfelelő konstansok.

Legyen  $k > p$  és  $k > q$  is. Ekkor  $u = a^k b^k c^k > p$ .

A lemma szerint az  $u$  szó  $vwyz$  alakban felbontható kell legyen, úgy, hogy  $\ell(xwy) \leq q < k$  és  $x$  és  $y$  párhuzamosan beiterálható.

De ekkor  $xy$ -ban nem lehet mindhárom betűből, így  $vwz$  nem lehet eleme  $L$ -nek, ami ellentmondás.

# Szóprobléma eldöntése

## Tétel:

Minden  $G=(N,T,P,S)$  környezetfüggetlen grammatika esetében eldönthető, hogy egytetszőleges  $u \in T^*$  szó benne van-e a  $G$  grammatika által generált nyelvben vagy sem.

Másképpen  $u \in L(G)$  igaz-e?

# Szóprobléma eldöntése

## Bizonyítás:

Az általánosság megszorítása nélkül feltehetjük, hogy  $G$  Chomsky normálformában van.

Az, hogy az üres szó benne van-e nyelvben az attól függ, hogy van-e  $S \rightarrow \varepsilon$  szabály  $G$ -ben.

Ha  $u$  nem az üres szó, akkor  $k = \ell(u) - 1 + \ell(u)$  lépésben levezethető kell legyen  $G$ -ben.

Mivel a  $k$  lépésben levezethető szavak halmaza véges, ezért eldönthető, hogy  $u$  benne van-e ebben a halmazban.



# Veremautomata

## Definíció:

$A = (\mathbf{Z}, Q, T, \delta, \mathbf{z_0}, q_0, F)$  rendezett hetest veremautomatának nevezzük, ahol

- $Z$  a verem szimbólumok ábécéje,
- $Q$  az állapotok nem üres véges halmaza,
- $T$  az input szimbólumok ábécéje,
- $\delta: \mathbf{Z} \times \mathbf{Q} \times (T \cup \{\epsilon\}) \rightarrow \mathcal{P}(\mathbf{Z}^* \times \mathbf{Q})$  leképezés az állapot-átmeneti függvény, ahol  $\delta$  véges részhalmazokba képez,
- $z_0 \in Z$  a kezdő veremszimbólum,
- $q_0 \in Q$  a kezdőállapot,
- $F \subseteq Q$  elfogadó állapotok halmaza.

# Veremautomata állapot-átmenete

Egy lépésben mindig kell egy jelet olvasni a verem tetejéről és csak egy jelet lehet elérni. Az input szalagról is egy jelet lehet olvasni, de nem kötelező.

Megváltoztatható az automata aktuális állapota, illetve a verem teteje. Egy lépésben egy egész sorozatot is beírhatunk a verembe.

Példák:

►  $\delta(\#,q,a) = \{(\#a,q)\}$

Jelentése: Ha  $\#$  van a verem tetején és  $a$  betű jön az inputon, akkor tegyük be  $a$ -t a verembe. Ne változtassunk az állapoton.

►  $\delta(\#,q,a) = \{(\epsilon,q)\}$

Jelentése: Ha  $\#$  van a verem tetején és  $a$  betű jön az inputon, akkor töröljük  $\#$ -t a veremből. Ne változtassunk az állapoton.

►  $\delta(\#,q,a) = \{(\#,r)\}$

Jelentése: Ha  $\#$  van a verem tetején és  $a$  betű jön az inputon, akkor ne változtassuk a verem tartalmát. Viszont váltsunk állapotot.

►  $\delta(\#,q,\epsilon) = \{(\#bb,r)\}$

Jelentése: Ha  $\#$  van a verem tetején és nem olvasunk az inputról, akkor tegyünk a verembe két  $b$  betűt és váltsunk állapotot is.

# Példa

Legyen  $L = \{a^n b^n \mid n \geq 1\}$ .

Ezt a nyelvet felismerő veremautomata:

$A = ( \{ \#, a \}, \{ q_0, q_1, q_2 \}, \{ a, b \}, \delta, \#, q_0, \{ q_2 \} )$

$$\delta(\#, q_0, a) = \{(\#a, q_0)\}$$

$$\delta(a, q_0, a) = \{(aa, q_0)\}$$


$$\delta(a, q_0, b) = \{(\varepsilon, q_1)\}$$

$$\delta(a, q_1, b) = \{(\varepsilon, q_1)\}$$

$$\delta(\#, q_1, \varepsilon) = \{(\#, q_2)\}$$

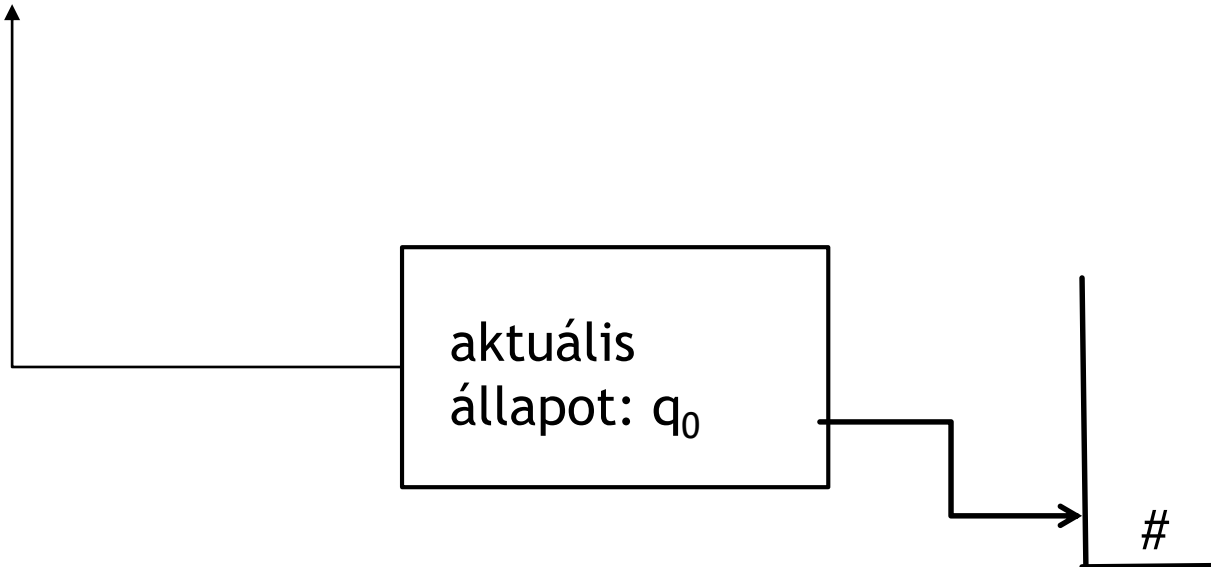

Megjegyzés: Itt most csak egy eleműek a halmazok. Gyakran ilyenkor nem írjuk ki a halmaz jelet.

# Példa - veremautomata gráf



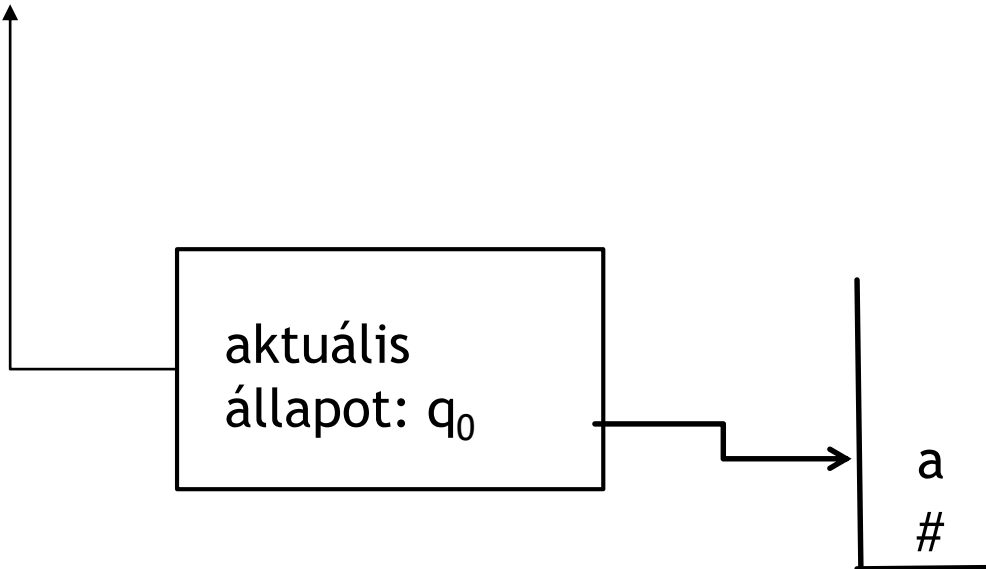

$\delta(\#, q_0, a) = (\#a, q_0)$   
 $\delta(a, q_0, a) = (aa, q_0)$   
 $\delta(a, q_0, b) = (\varepsilon, q_1)$   
 $\delta(a, q_1, b) = (\varepsilon, q_1)$   
 $\delta(\#, q_1, \varepsilon) = (\#, q_2)$

# Veremautomata működése





$\delta(\#, q_0, a) = (\#a, q_0)$   
 $\delta(a, q_0, a) = (aa, q_0)$   
 $\delta(a, q_0, b) = (\epsilon, q_1)$   
 $\delta(a, q_1, b) = (\epsilon, q_1)$   
 $\delta(\#, q_1, \epsilon) = (\#, q_2)$

# Veremautomata működése



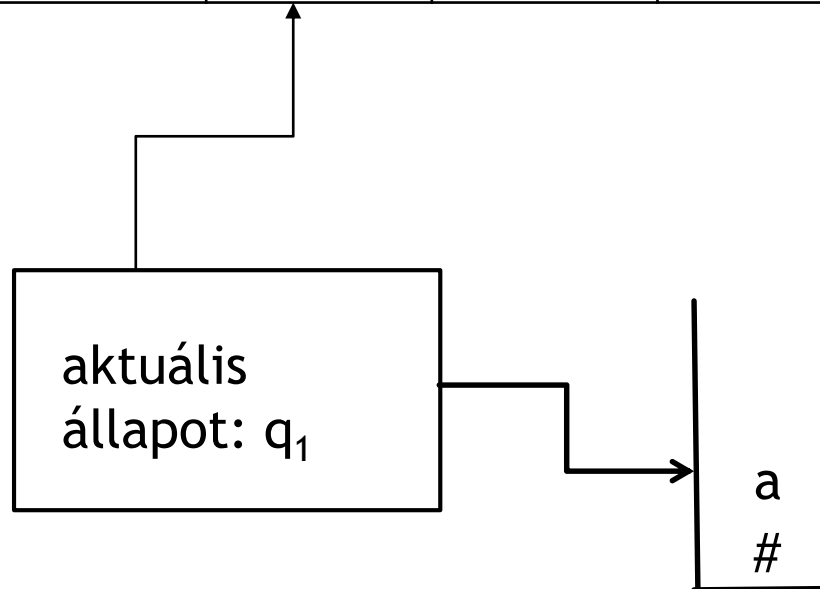
$\delta(\#, q_0, a) = (\#a, q_0)$   
 $\delta(a, q_0, a) = (aa, q_0)$   
 $\delta(a, q_0, b) = (\epsilon, q_1)$   
 $\delta(a, q_1, b) = (\epsilon, q_1)$   
 $\delta(\#, q_1, \epsilon) = (\#, q_2)$

# Veremautomata működése



$\delta(\#, q_0, a) = (\#a, q_0)$   
 $\delta(a, q_0, a) = (aa, q_0)$   
 $\delta(a, q_0, b) = (\epsilon, q_1)$   
 $\delta(a, q_1, b) = (\epsilon, q_1)$   
 $\delta(\#, q_1, \epsilon) = (\#, q_2)$



# Veremautomata működése



$\delta(\#, q_0, a) = (\#a, q_0)$   
 $\delta(a, q_0, a) = (aa, q_0)$   
 $\delta(a, q_0, b) = (\epsilon, q_1)$   
 $\delta(a, q_1, b) = (\epsilon, q_1)$   
 $\delta(\#, q_1, \epsilon) = (\#, q_2)$





# Veremautomata működése



$\delta(\#, q_0, a) = (\#a, q_0)$   
 $\delta(a, q_0, a) = (aa, q_0)$   
 $\delta(a, q_0, b) = (\varepsilon, q_1)$   
 $\delta(a, q_1, b) = (\varepsilon, q_1)$   
 $\delta(\#, q_1, \varepsilon) = (\#, q_2)$

# Veremautomata működése



$\delta(\#, q_0, a) = (\#a, q_0)$   
 $\delta(a, q_0, a) = (aa, q_0)$   
 $\delta(a, q_0, b) = (\epsilon, q_1)$   
 $\delta(a, q_1, b) = (\epsilon, q_1)$   
 $\delta(\#, q_1, \epsilon) = (\#, q_2)$

Az aktuális állapot elfogadó  
és a szót végig olvastuk.  
Tehát jó a szó.

# Veremautomata - alternatív jelöléssel

Ha  $\delta(z,q,a) = \{(w_1,r_1), \dots, (w_k,r_k)\}$  , akkor ezt a leképezést a következő szabályhalmazzal is jelölhetjük:

$$\mathbf{zqa} \rightarrow \mathbf{w_i r_i} , \text{ ahol } 1 \leq i \leq k.$$

Ha  $\delta(z,q,\varepsilon) = \{(w_1,r_1), \dots, (w_k,r_k)\}$  , akkor ezt a leképezést a következő szabályhalmazzal is jelölhetjük:

$$\mathbf{zq} \rightarrow \mathbf{w_i r_i} , \text{ ahol } 1 \leq i \leq k.$$

Tehát a szabályok baloldala **ZQT** vagy **ZQ** alakú és a jobboldala **Z\*Q** alakú.

# Veremautomata - alternatív jelöléssel

Példa:

Legyen  $L = \{a^n b^n \mid n \geq 1\}$ .

Ezt a nyelvet felismerő veremautomata:

$A = ( \{ \#, a \}, \{ q_0, q_1, q_2 \}, \{ a, b \}, \delta, \#, q_0, \{ q_2 \} )$

$\#q_0a \rightarrow \#aq_0$

$aq_0a \rightarrow aaq_0$

$aq_0b \rightarrow q_1$

$aq_1b \rightarrow q_1$

$\#q_1 \rightarrow \#q_2$

# Konfiguráció


Legyen  $A = (Z, Q, T, \delta, z_0, q_0, F)$  egy veremautomata és legyen  $\alpha \in Z^*QT^*$ .

Azt mondjuk  $\alpha$  az  $A$  veremautomata egy **konfigurációja**.

(A konfiguráció a veremautomata egy pillanatnyi állapotát írja le.)

Ha  $\alpha = zqu$ , ahol  $z \in Z^*$  és  $q \in Q$  és  $u \in T^*$  és

$z = z_1 \dots z_k$  és  $u = u_1 \dots u_m$ , akkor  $z_1$  a verem alján és  $z_k$  a tetején lévő karakter és  $u$  az input szöveg még el nem olvasott része, ahol  $u_1$  a soron következő karakter.



Kezdő konfiguráció:  $z_0q_0w$ , ahol  $w \in T^*$  az elemzendő szó.

# Közvetlen redukció - definíció

Legyen  $A = (Z, Q, T, \delta, z_0, q_0, F)$  egy veremautomata és legyenek  $\alpha, \beta \in Z^*QT^*$  konfigurációk.

(Konfiguráció: verem, aktuális állapot, input hátralévő része.)

Azt mondjuk, hogy az  $A$  veremautomata az  $\alpha$  konfigurációt a  $\beta$  konfigurációra **redukálja** közvetlenül (jelölés:  $\alpha \xRightarrow{A} \beta$ ),

ha van olyan  $z \in Z$ ,  $q, p \in Q$ ,  $a \in T \cup \{\varepsilon\}$  és  $r, u \in Z^*$ ,  $w \in T^*$  szó, hogy  $zqa \rightarrow up$  egy szabály és

$\alpha = r\mathbf{zq}aw$  és  $\beta = r\mathbf{up}w$  teljesül.

# Redukció - definíció

Legyen  $A = (Z, Q, T, \delta, z_0, q_0, F)$  egy veremautomata és legyenek  $\alpha, \beta \in Z^*QT^*$ .

(Konfiguráció: verem, aktuális állapot, input hátralévő része.)

Azt mondjuk, hogy az  $A$  veremautomata az  $\alpha$  konfigurációt a  $\beta$  konfigurációra redukálja (jelölés:  $\alpha \Rightarrow_A^* \beta$ ),

ha vagy  $\alpha = \beta$  vagy létezik  $\alpha_1, \dots, \alpha_k$  konfiguráció sorozat, hogy  $\alpha_1 = \alpha$  és  $\alpha_k = \beta$  és  $\alpha_i \Rightarrow_A \alpha_{i+1}$   $1 \leq i \leq k-1$ .

# Szó levezetése:

Legyen  $L = \{a^n b^n \mid n \geq 1\}$ .

Ezt a nyelvet felismerő veremautomata:

$A = ( \{ \#, a \}, \{ q_0, q_1, q_2 \}, \{ a, b \}, \delta, \#, q_0, \{ q_2 \} )$

$\#q_0a \rightarrow \#aq_0$

$aq_0a \rightarrow aaq_0$

$aq_0b \rightarrow q_1$

$aq_1b \rightarrow q_1$

$\#q_1 \rightarrow \#q_2$

$u = aabb$

$\#q_0aabb \xRightarrow{A} \#aq_0abb \xRightarrow{A} \#aaq_0bb \xRightarrow{A} \#aq_1b \xRightarrow{A} \#q_1 \xRightarrow{A} \#q_2$



# Veremautomata által elfogadott nyelv

Elfogadó állapottal felismerhető nyelv:

$$L(A) := \{ u \in T^* \mid \exists z_0 q_0 u \xRightarrow[A]{*} wr \text{ és } r \in F \text{ és } w \in Z^* \}.$$

Megjegyzés: Ez azt jelenti, hogy van olyan működése a veremautomatának, hogy kezdő konfigurációból indulva végig olvasva az inputot elfogadóállapotba jut.

Üres veremmel felismerhető nyelv:

$$N(A) := \{ u \in T^* \mid \exists z_0 q_0 u \xRightarrow[A]{*} r \text{ és } r \in Q \}.$$

Megjegyzés: Ez azt jelenti, hogy van olyan működése a veremautomatának, hogy kezdő konfigurációból indulva végig olvasva az inputot teljesen kiüríti a vermet.

# Determinisztikus veremautomata

Egy veremautomatát **determinisztikusnak** mondunk, ha minden  $\alpha \in Z^+QT^*$  konfiguráció esetén egyetlen konfiguráció vezethető le közvetlenül  $\alpha$  -ból.

Megjegyzés: Ez azt jelenti, hogy nincs két olyan szabály, amelynek azonos a baloldala, valamint, ha  $zq$  egy baloldal, akkor nincs  $zqa$  baloldal egyetlen terminálisra sem.

# Determinisztikus és nemdeterminisztikus veremautomaták kapcsolata

A determinisztikus veremautomatával felismerhető nyelvek családja szűkebb, mint a nemdeterminisztikussal felismerhető nyelvek családja.

(Például a szimmetrikus szavak nem ismerhetők fel determinisztikus veremautomatával.)

# Szimmetrikus szavakat felismerő veremautomata - alternatív jelöléssel

Példa: Legyen  $L = \{uu^{-1} \mid u \in \{a,b\}^+\}$ .

Ezt a nyelvet felismerő veremautomata:

$A = (\{\#, a, b\}, \{q_0, q_1, q_2\}, \{a, b\}, \delta, \#, q_0, \{q_2\})$

$\#q_0a \rightarrow \#aq_0$

$\#q_0b \rightarrow \#bq_0$

$aq_0a \rightarrow aaq_0$

$bq_0b \rightarrow bbq_0$

$aq_0b \rightarrow abq_0$

$bq_0a \rightarrow baq_0$

$aq_0a \rightarrow q_1$

$bq_0b \rightarrow q_1$

$aq_1a \rightarrow q_1$

$bq_1b \rightarrow q_1$

$\#q_1 \rightarrow q_2$

## Szó levezetése:

$\#q_0a \rightarrow \#aq_0$

$aq_0a \rightarrow aaq_0$

$aq_0b \rightarrow abq_0$

$aq_0a \rightarrow q_1$

$aq_1a \rightarrow q_1$

$\#q_1 \rightarrow q_2$

$\#q_0b \rightarrow \#bq_0$

$bq_0b \rightarrow bbq_0$

$bq_0a \rightarrow baq_0$

$bq_0b \rightarrow q_1$

$bq_1b \rightarrow q_1$

$u = abba$

$\#q_0abba \xRightarrow{A} \#aq_0bba \xRightarrow{A} \#abq_0ba \xRightarrow{A} \#abbq_0a \xRightarrow{A} \#abbaq_0 // \text{ nem jó}$

$\#q_0abba \xRightarrow{A} \#aq_0bba \xRightarrow{A} \#abq_0ba \xRightarrow{A} \#aq_1a \xRightarrow{A} \#q_1 \xRightarrow{A} q_2 // \text{ jó a szó}$

# A kétféle elfogadás kapcsolata.

## Lemma1:

Bármely  $A$  veremautomatához megadható  $A'$  veremautomata úgy, hogy  $N(A')=L(A)$ .

## Lemma2:

Bármely  $A$  veremautomatához megadható  $A'$  veremautomata úgy, hogy  $L(A')=N(A)$ .

Megjegyzés: Ez azt jelenti, hogy ha egy nyelvhez építhető elfogadó állapottal felismerő veremautomata, akkor építhető üresveremmel felismerő veremautomata és fordítva.

# A 2-es nyelvcsalád és a veremautomaták kapcsolata

## Tétel:

Ha  $L \in \mathcal{L}_2$  , akkor megadható egy  $A$  veremautomata úgy, hogy  $L=N(A)$ , azaz  $\mathcal{L}_2 \subseteq \mathcal{L}_{1V}$  .

# A 2-es nyelvcsalád és a veremautomaták kapcsolata

## Bizonyítás:

Legyen  $G=(N,T,P,S)$  egy környezetfüggetlen (2-es típusú) grammatika, amelyre  $L=L(G)$ .

Ekkor  $A=(T \cup N, \{q_0\}, T, \delta, S, q_0, \emptyset)$ , ahol  $\delta$  a következő:

- $Xq_0 \rightarrow w^{-1}q_0$  akkor és csak akkor, ha  $X \rightarrow w \in P$ ,  $X \in N$ ,  $w \in (T \cup N)^*$ ;
- $aq_0a \rightarrow q_0$  akkor és csak akkor, ha  $a \in T$ .

Megjegyzés: A egy egyállapotú üresveremmel elfogadó automata.



# A 2-es nyelvcsalád és a veremautomaták kapcsolata

## Bizonyítás folytatása:

A verem segítségével egy az elemzendő szó egy legbal levezetését szimuláljuk.

Ha nemterminális van a verem tetején, akkor valamelyik rá vonatkozó szabály jobboldalára cseréljük.

Ha terminális van a verem tetején, akkor az aktuális inputtal egyeztetjük, ha azonosak, akkor kivesszük a terminálist a veremből és tovább lépünk az inputban.

# Példa

Legyen  $L = \{a^n b^n \mid n \geq 1\}$  és  $L = L(G)$ , ahol

$$G = (\{S\}, \{a, b\}, P, S)$$

$$P: S \rightarrow aSb$$

$$S \rightarrow ab$$

Ezt a nyelvet felismerő veremautomata:

$$A = (\{S\}, \{q_0\}, \{a, b\}, \delta, S, q)$$

$$Sq_0 \rightarrow bSa q_0 \quad // \text{fordítva kell a verembe tenni}$$

$$Sq_0 \rightarrow ba$$

$$aq_0a \rightarrow q_0$$

$$bq_0b \rightarrow q_0$$

# Példa

u = aabb szó elemzése:

$$Sq_0 \rightarrow bSa q_0$$

$$Sq_0 \rightarrow ba$$

$$aq_0a \rightarrow q_0$$

$$bq_0b \rightarrow q_0$$

$$\underset{A}{Sq_0}aabb \Rightarrow \underset{A}{bSa}q_0aabb \Rightarrow \underset{A}{bSq_0}abb \Rightarrow \underset{A}{bba}q_0abb \Rightarrow$$

$$\underset{A}{\Rightarrow} \underset{A}{bb}q_0\underset{A}{bb} \Rightarrow \underset{A}{bq_0}b \underset{A}{\Rightarrow} q_0, \text{ azaz } u \text{ jó szó.}$$

# Példa

$$Sq_0 \rightarrow bSa q_0$$

$$Sq_0 \rightarrow ba$$

$$aq_0a \rightarrow q_0$$

$$bq_0b \rightarrow q_0$$

u = aabb szó elemzése:

konfiguráció: verem, aktuális állapot, input ( $Z^*QT^*$ )

inicializálás:

$Sq_0aabb$




$bSa q_0aabb$



$bSq_0abb$

szintaxis fa



# Példa

u = aabb szó elemzése:

$Z^*QT^*$

$Sq_0aabb$   
 $bSaq_0aabb$   
 $bSq_0abb$   
 $\downarrow$   
 $bbaq_0abb$   
 $bbq_0bb$   
 $bq_0b$   
 $q_0$


$Sq_0 \rightarrow bSaq_0$

$Sq_0 \rightarrow ba$

$aq_0a \rightarrow q_0$

$bq_0b \rightarrow q_0$

szintaxis fa



# A 2-es nyelvcsalád és a veremautomaták kapcsolata

## Tétel:

Minden A veremautomatához megadható egy környezetfüggetlen G grammatika úgy, hogy  $L(G)=N(A)$ , azaz  $\mathcal{L}_{1v} \subseteq \mathcal{L}_2$ .

Megjegyzés: A fordított tételt nem bizonyítjuk.

*Köszönöm a figyelmet!*